Respostes Pràctica 2

January 4, 2021

1 Dataset

El dataset emprat en aquesta pràctica és el generat a la PRA1 de l'assignatura, on vam recollir les dades de la web de Fotocasa dels pisos de lloguer a la ciutat de Barcelona (amb data d'octubre de 2020), mitjançant scraping.

L'objectiu de l'anàlisi de les dades d'aquest dataset és:

- Respondre a la pregunta de si hi ha diferències significatives en els preus de lloguer entre els diferents barris de la ciutat.
- Respondre a la pregunta de si hi ha diferències significatives en els preus de lloguer entre les diferents agències.
- Crear un model de regressió que permeti predir el preu d'un habitatge segons les seves característiques.
- Crear un model supervisat que ens digui, donades les característiques d'un lloguer i el seu preu, si aquest és un preu inflat o no.
- Crear un model no supervisat que ens permeti identificar clústers d'observacions amb el preu inflat respecte al preu mitjà teòric del seu barri, i plasmar aquests clústers a un mapa de coordenades (latitud, longitud), per tal de veure si es corresponen amb zones específiques de la ciutat.

2 Selecció de dades

Primerament, determinarem quines són les variables del nostre dataset i el seu tipus. Seguidament, eliminarem aquelles que no aportin informació útil de cara a la nostra anàlisi. Finalment, farem una eliminació de files duplicades.

[1]:
```
import pandas as pd

apartments = pd.read_csv('../csv/data_initial.csv')
```

2.1 Eliminació de dimensions

[2]:
```
apartments.dtypes
```

[2]:
```
id                      int64
address                object
bathrooms               int64
```

```
building_subtype        object
building_type           object
conservation_state     float64
date                    object
discount                 int64
floor_elevator           int64
is_new_construction       bool
latitude               float64
link                    object
longitude              float64
price                  float64
realestate              object
realestate_id            int64
rooms                    int64
sqft_m2                  int64
neighbourhood           object
neighb_meanprice       float64
dtype: object
```

Donats els objectius de la nostra anàlisi, hi ha certes columnes del dataset que podem eliminar:

- **id**, que simplement conté l'índex de la fila dintre del dataset, de moment la deixem per si hem de seleccionar files per aquest índex.
- **address**, que conté la direcció del pis. Ja tenim el barri disponible a la columna **neighbourhood** i per tant, aquest camp aporta informació innecessària a la nostra anàlisi.
- **date**, que conté la data en la qual es va recollir la mostra. Solament la vam recollir un dia específic i per tant, no aporta cap informació rellevant a l'anàlisi actual.
- **realestate_id**, que conté l'identificador de l'agència que oferta el pis en lloguer. Ens preferim quedar amb el nom, ja que ens permetrà visualitzar la informació de manera més clara

[3]:
```
apartments = apartments.drop(columns=['address', 'date', 'realestate_id'])
```

2.2 Eliminació de files duplicades

L'eliminació de files duplicades la portarem a terme segons la variable **link**. Si tenim dues o més observacions del mateix pis de la web de Fotocasa, ens quedarem únicament amb la primera:

[4]:
```
apartments.loc[apartments.duplicated('link')]
```

[4]:

	id	bathrooms	building_subtype	building_type	conservation_state	\
39	39	1	Apartment	Flat	NaN	
40	40	1	Apartment	Flat	NaN	
41	41	1	Apartment	Flat	NaN	
42	42	1	Apartment	Flat	NaN	
43	43	1	Apartment	Flat	NaN	
…	…	…	…	…	…	
11803	11803	2	Attic	Flat	1.0	
11804	11804	2	Attic	Flat	1.0	

```
12007  12007          5             Flat          Flat                 2.0
12061  12061          2        Apartment          Flat                 NaN
12116  12116          7     House_Chalet          Flat                 2.0

       discount  floor_elevator  is_new_construction  latitude  \
39            0               0                False  41.38071
40            0               0                False  41.38071
41            0               0                False  41.38071
42            0               0                False  41.38071
43            0               0                False  41.38071
…          …              …                    …       …
11803       200               1                False  41.39394
11804       200               1                False  41.39394
12007         0               1                False  41.39514
12061       594               0                False  41.39498
12116         0               0                False  41.39722

                                                    link  longitude   price  \
39     /es/alquiler/vivienda/barcelona-capital/el-rav…   2.168707   525.0
40     /es/alquiler/vivienda/barcelona-capital/el-rav…   2.168707   525.0
41     /es/alquiler/vivienda/barcelona-capital/el-rav…   2.168707   525.0
42     /es/alquiler/vivienda/barcelona-capital/el-rav…   2.168707   525.0
43     /es/alquiler/vivienda/barcelona-capital/el-rav…   2.168707   525.0
…                                                      …        …     …
11803  /es/alquiler/vivienda/barcelona-capital/aire-a…   2.121359  3700.0
11804  /es/alquiler/vivienda/barcelona-capital/aire-a…   2.121359  3700.0
12007  /es/alquiler/vivienda/barcelona-capital/aire-a…   2.141838  5300.0
12061  /es/alquiler/vivienda/barcelona-capital/aire-a…   2.147670  6073.0
12116  /es/alquiler/vivienda/barcelona-capital/aire-a…   2.137248  9000.0

                                          realestate  rooms  sqft_m2  \
39     INVERSIONES INMOBILIARIAS Y FINANCIERAS SANT A…      0       35
40     INVERSIONES INMOBILIARIAS Y FINANCIERAS SANT A…      0       35
41     INVERSIONES INMOBILIARIAS Y FINANCIERAS SANT A…      0       35
42     INVERSIONES INMOBILIARIAS Y FINANCIERAS SANT A…      0       35
43     INVERSIONES INMOBILIARIAS Y FINANCIERAS SANT A…      0       35
…                                                      …    …      …
11803                  Stipek Ferrer Premium Properties      4      280
11804                  Stipek Ferrer Premium Properties      4      280
12007                                       Max Ricart      6      280
12061                                         Homelike      4      100
12116                                FINQUES CANO PUJOL      8      560

               neighbourhood  neighb_meanprice
39                  el raval         14.323614
40                  el raval         14.323614
41                  el raval         14.323614
```

```
42                    el raval         14.323614
43                    el raval         14.323614
…                        …               …
11803                  sarrià          16.866645
11804                  sarrià          16.866645
12007  sant gervasi - galvany          15.275452
12061  sant gervasi - galvany          15.275452
12116  sant gervasi - galvany          15.275452

[2268 rows x 17 columns]
```

[5]:
```
apartments = apartments.drop_duplicates('link')
```

2.3 Tipus de dades

Si observem els tipus de dades anteriors, es pot veure com **conservation_state**, **building_subtype** i **building_type** poden ser variables categòriques, o com **floor_elevator** és en realitat una variable booleana. Podem aplicar la conversió sobre aquestes variables amb l'objectiu de millorar l'anàlisi:

[6]:
```
apartments = apartments.astype({
    'conservation_state': 'category',
    'building_subtype': 'category',
    'building_type': 'category',
    'floor_elevator': 'bool',
    'neighbourhood':'category'
})
```

3 Neteja de dades

3.1 Valors buits

Anem a determinar quins són els valors buits de cadascuna de les columnes:

[7]:
```
apartments.isna().sum()
```

[7]:
```
id                      0
bathrooms               0
building_subtype        0
building_type           0
conservation_state    5340
discount                0
floor_elevator          0
is_new_construction     0
latitude                0
link                    0
longitude               0
```

```
price                   4
realestate            106
rooms                   0
sqft_m2                 0
neighbourhood           1
neighb_meanprice        1
dtype: int64
```

Veiem que molts habitatges no tenen informació sobre l'estat de conservació. Omplirem amb -1 aquells que no en tinguin:

[8]:
```
apartments['conservation_state'] = apartments['conservation_state'].cat.
↪add_categories(-1)

apartments['conservation_state'] = apartments['conservation_state'].fillna(-1)
```

Donat que volem respondre a la pregunta de si hi ha diferències de preu entre les diferents agències, eliminem les observacions que no tenen agència:

[9]:
```
apartments = apartments.dropna(subset=['realestate'])
apartments.isna().sum()
```

[9]:
```
id                    0
bathrooms             0
building_subtype      0
building_type         0
conservation_state    0
discount              0
floor_elevator        0
is_new_construction   0
latitude              0
link                  0
longitude             0
price                 4
realestate            0
rooms                 0
sqft_m2               0
neighbourhood         1
neighb_meanprice      1
dtype: int64
```

Pel que fa al preu, es tracta de poques observacions que tenen un valor buit per aquesta variable. Com que l'objectiu d'aquesta anàlisi gira entorn del preu, decidim inserir la informació de forma manual consultant la web de Fotocasa:

[10]:
```
apartments[apartments.price.isna()]['link']
```

[10]:
```
12154    /es/alquiler/vivienda/barcelona-capital/calefa…
12155    /es/alquiler/vivienda/barcelona-capital/ascens…
12156    /es/alquiler/vivienda/barcelona-capital/aire-a…
12157    /es/alquiler/vivienda/barcelona-capital/aire-a…
Name: link, dtype: object
```

Les quatre observacions, un cop consultat el link al web de Fotocasa, corresponen a habitatges que no tenen preu, indicant-ho al web com per "a consultar". Com necessitem treballar amb els preus, procedirem a eliminar aquestes dades.

[11]:
```
apartments = apartments.dropna(subset=['price'])
```

Finalment, ens queda omplir manualment les observacions que no tenen barri, de nou, mitjançant l'enllaç de Fotocasa per veure si podem determinar aquesta informació:

[12]:
```
apartments[apartments.neighbourhood.isna()]
```

[12]:
```
         id  bathrooms building_subtype building_type conservation_state  \
1384  1384          1             Flat          Flat               -1.0

      discount  floor_elevator  is_new_construction  latitude  \
1384         0           False                False  41.35395

                                                 link  longitude  price  \
1384  /es/alquiler/vivienda/barcelona-capital/la-mar…   2.148532  750.0

         realestate  rooms  sqft_m2 neighbourhood  neighb_meanprice
1384  FINCAS LAFONT      3       70           NaN               NaN
```

Veiem que es correspon amb el barri de "La marina de Port", així que li assignem el preu mitjà d'aquest barri.

[13]:
```
mean_price_marina = float(apartments[apartments['neighbourhood']=='la marina de␣
↪port'].head(1)['neighb_meanprice'])

apartments.loc[apartments.id ==1384, 'neighbourhood'] = 'la marina de port'
apartments.loc[apartments.id ==1384, 'neighb_meanprice'] = mean_price_marina
```

Podem observar que ara el dataset no té valors buits:

[14]:
```
apartments.isna().sum()
```

[14]:
```
id                    0
bathrooms             0
building_subtype      0
building_type         0
conservation_state    0
discount              0
```

```
floor_elevator          0
is_new_construction     0
latitude                0
link                    0
longitude               0
price                   0
realestate              0
rooms                   0
sqft_m2                 0
neighbourhood           0
neighb_meanprice        0
dtype: int64
```

Podem eliminar l'id:

[15]:
```
apartments = apartments.drop(columns=['id'])
```

3.2 Outliers

El que primer farem, serà visualitzar a gràfics de tipus boxplot cadascuna de les variables quantitatives per tal de determinar si tenim o no outliers:

[16]:
```
import matplotlib.pyplot as plt
import matplotlib.colors as colors
import numpy as np
import math

fig = plt.figure(figsize=(16,10))
numeric_attributes = apartments.select_dtypes(include=np.number).columns
for idx, column in enumerate(numeric_attributes):
    ax = fig.add_subplot(2, math.ceil(len(numeric_attributes)/2), idx+1)
    ax.boxplot(apartments[[column]], labels=[column])
```

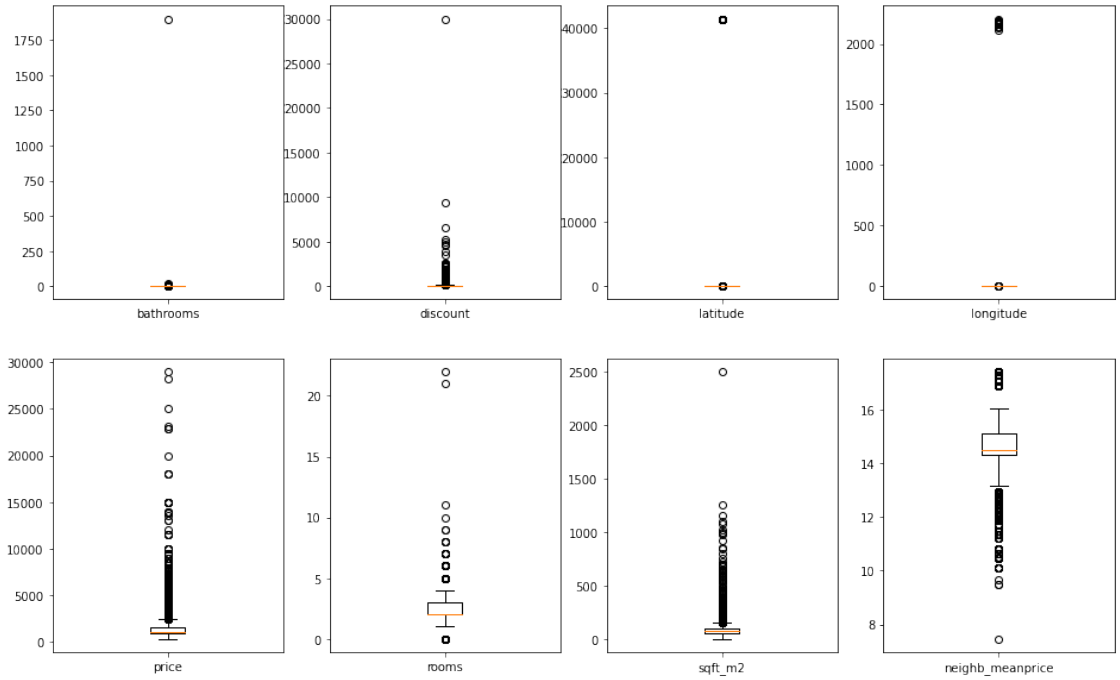

Sembla evident que tenim prou valors extrems al dataset per a cadascuna de les variables quantitatives. El que cal és determinar si aquests valors són reals i per tant els hem de tenir en compte a l'anàlisi, o d'altra banda podem eliminar aquells que considerem outliers.

3.2.1 Price

Si seleccionem els 5 preus més alts del dataset, podem comprovar com es tracta de valors vàlids quan accedim al detall a la pàgina de Fotocasa:

[17]:
```
apartments.sort_values('price', ascending=False).head()[['link', 'rooms',␣
↪'bathrooms', 'realestate', 'sqft_m2', 'price']]
```

[17]:

	link	rooms	bathrooms	realestate	sqft_m2	price
12153	/es/alquiler/vivienda/barcelona-capital/aire-a…	4	4	VIP PISOS	600	29000.0
12152	/es/alquiler/vivienda/barcelona-capital/aire-a…	8	7	Homelike	550	28279.0
12151	/es/alquiler/vivienda/barcelona-capital/aire-a…	21	21	ENGEL & VOELKERS	2500	25000.0
12150	/es/alquiler/vivienda/barcelona-capital/aire-a…	3	2	Homelike	85	23092.0
12149	/es/alquiler/vivienda/barcelona-capital/aire-a…	2	1	Homelike	54	22839.0

Sembla per tant que existeixen uns pocs pisos al dataset amb preus molt elevats, i característiques com nombre d'habitacions, metres quadrats o nombre de banys amb valors que tot i semblar extrems, són vàlids. Per aquest motiu, decidim **mantenir** aquestes observacions per tal de dur a terme l'anàlisi de dades.

3.2.2 Latitude i Longitude

Si s'examinen les variables latitude i longitude, hi veiem valors sospitosos. La latitud és un valor que oscil · la entre -90 i 90, mentre que la longitud ho fa entre -180 i 180. Per tant, qualsevol observació d'aquestes variables fora d'aquest rang es podria considerar un outlier. D'altra banda, esperem que tots els habitatges es trobin a la ciutat de Barcelona, per tant, que tinguin coordenades molt semblants.

[18]:
```
apartments[(apartments['latitude'] > 90) | (apartments['latitude'] < -90)].
↪sort_values('latitude', ascending=False).head(100)[['link', 'latitude',␣
↪'longitude', 'neighbourhood', 'price']]
```

[18]:

	link	latitude	longitude	\
3979	/es/alquiler/vivienda/barcelona-capital/aire-a…	41436.0	2.173259	
4177	/es/alquiler/vivienda/barcelona-capital/aire-a…	41428.0	2.189229	
1266	/es/alquiler/vivienda/barcelona-capital/ascens…	41424.0	2.151020	
3694	/es/alquiler/vivienda/barcelona-capital/aire-a…	41422.0	2.188695	
6027	/es/alquiler/vivienda/barcelona-capital/calefa…	41418.0	2.171966	
…	…	…	…	
4181	/es/alquiler/vivienda/barcelona-capital/aire-a…	41373.0	2.157460	
6920	/es/alquiler/vivienda/barcelona-capital/aire-a…	41372.0	2.138111	
7003	/es/alquiler/vivienda/barcelona-capital/aire-a…	41372.0	2.127435	
2567	/es/alquiler/vivienda/barcelona-capital/aire-a…	41372.0	2.147444	
171	/es/alquiler/vivienda/barcelona-capital/amuebl…	41371.0	2.148023	

	neighbourhood	price
3979	porta	950.0
4177	la sagrera	955.0
1266	la teixonera	750.0
3694	sant antoni	910.0
6027	el guinardó	1100.0
…	…	…
4181	el poble sec - aei parc montjuïc	955.0
6920	la bordeta	1200.0
7003	sants	1200.0
2567	la font de la guatlla	850.0
171	la font de la guatlla	580.0

[87 rows x 5 columns]

Pel que fa a **latitude**, sembla que existeix un error a l'hora d'interpretar els decimals. Les observacions que tenim pels pisos de Barcelona, tenen una latitud que oscil · la entre els següents valors:

[19]:
```
apartments[(apartments['latitude']) < 90]['latitude'].max()
```

[19]:
```
41.46262
```

[20]:
```
apartments[(apartments['latitude']) < 90]['latitude'].min()
```

[20]:
```
41.35395
```

Podem corregir fàcilment els valors incorrectes, ja que tots són superiors a 41370, dividint el valor de **latitude** entre 1000 per a aquestes observacions:

[21]:
```
apartments.loc[apartments['latitude'] > 41370, 'latitude'] =␣
↪apartments['latitude']/1000
apartments.sort_values('latitude', ascending=False).head(10)[['link',␣
↪'latitude', 'longitude', 'neighbourhood', 'price']]
```

[21]:

	link	latitude	longitude	neighbourhood	price
228	/es/alquiler/vivienda/barcelona-capital/terraz…	41.46262	2.180195	ciutat meridiana	600.0
15	/es/alquiler/vivienda/barcelona-capital/terraz…	41.45524	2.174660	torre baró	490.0
609	/es/alquiler/vivienda/barcelona-capital/terraz…	41.45345	2.190106	la trinitat vella	675.0
978	/es/alquiler/vivienda/barcelona-capital/amuebl…	41.45231	2.191007	la trinitat vella	715.0
509	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.45208	2.192924	la trinitat vella	650.0
578	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.45131	2.190549	la trinitat vella	664.0
296	/es/alquiler/vivienda/barcelona-capital/terraz…	41.45129	2.189722	la trinitat vella	647.0
222	/es/alquiler/vivienda/barcelona-capital/terraz…	41.45118	2.189822	la trinitat vella	600.0
1344	/es/alquiler/vivienda/barcelona-capital/no-amu…	41.45047	2.191933	la trinitat vella	750.0
7797	/es/alquiler/vivienda/barcelona-capital/calefa…	41.44968	2.190399	la trinitat vella	1250.0

Podem aplicar el mateix procés per al camp **longitude**:

[22]:
```
apartments[(apartments['longitude'] > 180) | (apartments['longitude'] < -180)].
↪sort_values('longitude', ascending=False).head(100)[['link', 'latitude',␣
↪'longitude', 'neighbourhood', 'price']]
```

[22]:

	link	latitude	longitude	neighbourhood	price
4023	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.39861	2206.0	el poblenou	950.0
1430	/es/alquiler/vivienda/barcelona-capital/ascens…	41.41937	2188.0	navas	750.0
3229	/es/alquiler/vivienda/barcelona-capital/calefa…	41.38230	2188.0	la barceloneta	900.0
2042	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.43369	2186.0	sant andreu	800.0
411	/es/alquiler/vivienda/barcelona-capital/sant-p…	41.38697	2177.0	sant pere, santa caterina i la ribera	650.0
4265	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.38697	2177.0	sant pere, santa caterina i la ribera	975.0
5685	/es/alquiler/vivienda/barcelona-capital/calefa…	41.40808	2169.0	el baix guinardó	1090.0
5683	/es/alquiler/vivienda/barcelona-capital/calefa…	41.40816	2169.0	el baix guinardó	1090.0
2899	/es/alquiler/vivienda/barcelona-capital/ascens…	41.37688	2168.0	el raval	855.0
896	/es/alquiler/vivienda/barcelona-capital/can-ba…	41.41630	2164.0	can baró	700.0
8972	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.39114	2164.0	la dreta de l'eixample	1490.0
1140	/es/alquiler/vivienda/barcelona-capital/ascens…	41.38768	2161.0	l'antiga esquerra de l'eixample	738.0
8145	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.39986	2159.0	la vila de gràcia	1300.0
7232	/es/alquiler/vivienda/barcelona-capital/terraz…	41.40638	2146.0	el putxet i el farró	1200.0
7437	/es/alquiler/vivienda/barcelona-capital/calefa…	41.40638	2146.0	el putxet i el farró	1200.0
10100	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.40403	2142.0	el putxet i el farró	1750.0
9729	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.39605	2137.0	sant gervasi - galvany	1650.0
10196	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.38006	2111.0	la maternitat i sant ramon	1800.0

Les observacions pels pisos de Barcelona tenen una longitud que oscil · la entre els següents valors:

[23]:
```
apartments[(apartments['longitude']) < 180]['longitude'].max()
```

[23]:
```
2.224126
```

[24]:
```
apartments[(apartments['longitude']) < 180]['longitude'].min()
```

[24]:
```
2.0915220000000003
```

De nou, si dividim els valors de **longitude** superiors a 2110 entre 1000, corregirem els valors d'aquestes observacions:

[25]:
```
apartments.loc[apartments['longitude'] > 2110, 'longitude'] =␣
↪apartments['longitude']/1000
apartments.sort_values('longitude', ascending=False).head(10)[['link',␣
↪'latitude', 'longitude', 'neighbourhood', 'price']]
```

[25]:

	link	latitude	longitude	\
8502	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.41129	2.224126	
10272	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.41315	2.222797	
11252	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.41155	2.221454	
10433	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.41163	2.220950	
10232	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.41353	2.220937	
9594	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.41261	2.220891	
8157	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.41361	2.220773	
11048	/es/alquiler/vivienda/barcelona-capital/calefa…	41.41253	2.220563	
8611	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.40981	2.220171	
11098	/es/alquiler/vivienda/barcelona-capital/aire-a…	41.41261	2.220109	

	neighbourhood	price
8502	el besòs i el maresme	1350.0
10272	el besòs i el maresme	1800.0
11252	el besòs i el maresme	2600.0
10433	el besòs i el maresme	1900.0
10232	el besòs i el maresme	1800.0
9594	el besòs i el maresme	1600.0
8157	el besòs i el maresme	1300.0
11048	el besòs i el maresme	2400.0
8611	diagonal mar i el front marítim del poblenou	1400.0
11098	el besòs i el maresme	2500.0

3.2.3 Bathrooms

Per a aquest camp, tot i que hem comentat que hi ha valors alts que considerem vàlids, si observem el boxplot veiem que hi ha una observació que té un valor molt extrem:

[26]:
```
apartments[apartments['bathrooms'] > 100][['link', 'bathrooms', 'rooms',␣
↪'sqft_m2', 'price']]
```

[26]:

	link	bathrooms	rooms	\
10875	/es/alquiler/vivienda/barcelona-capital/aire-a…	1901	3	

	sqft_m2	price
10875	135	2200.0

A la web de Fotocasa, s'indica també aquest valor. Tot i això, no és lògic tenir 1901 banys a un pis de 135 metres quadrats de 3 habitacions i per tant, decidim eliminar aquesta observació:

[27]:
```
apartments = apartments.drop(index=10875)
```

[28]:
```
apartments.bathrooms.max()
```

[28]: 21

3.2.4 Superfície

[29]:
```
apartments = apartments[apartments['sqft_m2'] != 0]
```

3.3 Transformació de dades

Afegirem una nova variable que calculi la diferència de cada habitatge sobre el preu mitjà del barri:

[30]:
```
apartments['diff_mitjana'] = ((apartments['price']/(apartments.
↪neighb_meanprice*apartments.sqft_m2))-1)*100
```

3.4 Fitxer csv amb les dades finals a analitzar

[31]:
```
apartments.to_csv('../csv/data_clean.csv')
```

4 Anàlisi

4.1 Grups a comparar

- Es vol comparar si hi ha diferències de preus estadísticament significatives entre els diferents barris. Cada barri serà, per tant, un grup diferent.
- Es vol comparar si hi ha diferències de preus estadísticament significatives entre les diferents agències. Cada agència serà, per tant, un grup diferent.

4.2 Comprovació de la normalitat de la variable price

Atès que les anàlisis d'estadística inferencial que portarem a terme impliquen en tots els casos la variable **price**, serà necessari comprovar prèviament la normalitat d'aquesta variable per tal de saber si hem d'aplicar proves paramètriques o no paramètriques.

Anem a visualitzar l'histograma i el gràfic Q-Q de la variable price per tenir una orientació visual de si aquesta variable segueix o no una distribució normal:

[32]:
```
from scipy import stats

fig = plt.figure(figsize=(16,8))

ax = fig.add_subplot(1, 2, 1)
ax.hist(apartments.price, 500, density=True)
```

```
ax = fig.add_subplot(1, 2, 2)
stats.probplot(apartments.price, dist='norm', plot=plt)
pass
```

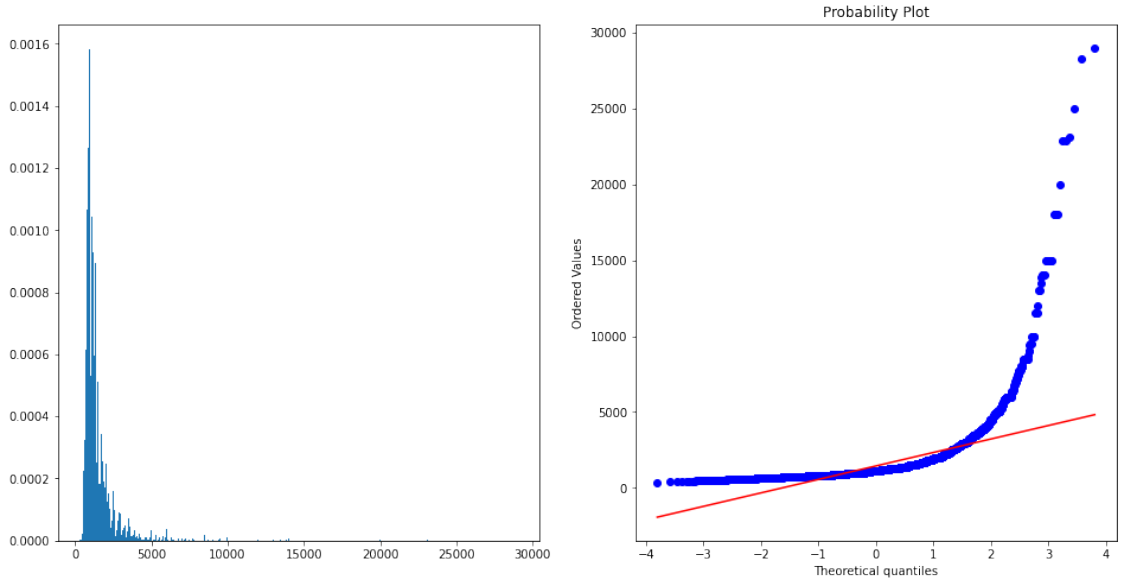

A simple vista, no sembla que la variable **price** segueixi una distribució normal. Per tal de comprovar-ho, portarem a terme la prova de Kolmogorov-Smirnov. El motiu de portar a terme aquesta prova i no la de Shapiro-Wilk, és perquè amb la implementació de Scipy, per un nombre de mostres superior a 5000, el p-value pot no ésser precís.

[33]:
```
stats.kstest(apartments.price, 'norm', args=(apartments.price.mean(),␣
↪apartments.price.std()))
```

[33]:
```
KstestResult(statistic=0.2449490400964482, pvalue=0.0)
```

Podem veure que el p-value és 0 en el nostre cas, més petit que el valor de significació escollit: 0.05. Per tant podem rebutjar la hipòtesi nul · la i concloure que la variable **price no segueix una distribució normal**.

4.3 Comprovació de l'homoscedasticitat de la variable price per als diferents grups

Per comprovar l'homoscedasticitat de la variable **price** per als diferents grups que volem comparar, emprarem el test de Fligner-Killeen, ja que prèviament hem observat que aquesta variable no segueix una distribució normal.

4.3.1 Homoscedasticitat dels preus dels barris

[34]:
```
neighbourhood_grouped_samples = apartments.groupby('neighbourhood')['price'].
↪apply(pd.Series.tolist).tolist()
stats.fligner(*neighbourhood_grouped_samples)
```

[34]:
```
FlignerResult(statistic=2104.733108385882, pvalue=0.0)
```

Donat el p-value és < 0.05 (el valor de significació escollit), podem concloure doncs que **price** presenta variàncies estadísticament diferents entre els barris de Barcelona.

4.3.2 Homoscedasticitat dels preus de les agències

[35]:
```
realestate_grouped_samples = apartments.groupby('realestate')['price'].apply(pd.
↪Series.tolist).tolist()
stats.fligner(*realestate_grouped_samples)
```

[35]:
```
FlignerResult(statistic=3493.643125045974, pvalue=1.0719141814502517e-260)
```

Donat que el p-value és < 0.05 (el valor de significació escollit), podem concloure que **price** presenta variàncies estadísticament diferents entre les agències immobiliàries.

4.4 Comprovació de mitjanes de la variable price per als diferents grups

Ja hem vist com la variable **price** no segueix una distribució normal, i com per als grups que es volen analitzar, la variància de **price** entre ells presenta diferències estadísticament significants. Donat tot això, haurem d'emprar proves no paramètriques, en concret el test de Kruskal-Wallis, per tal de saber si la mitjana entre els diferents grups (que són més de dos tant en el cas dels barris com en el cas de les agències) presenta diferències estadísticament significants.

4.4.1 Comparació de mitjanes de preus entre els diferents barris

[36]:
```
stats.kruskal(*neighbourhood_grouped_samples)
```

[36]:
```
KruskalResult(statistic=2637.6757596495586, pvalue=0.0)
```

Donat que el p-value és < 0.05 (el valor de significació escollit), podem concloure que hi ha diferències de preu estadísticament significatives entre els barris de Barcelona.

4.4.2 Comparació de mitjanes de preus entre les diferents agències

[37]:
```
stats.kruskal(*realestate_grouped_samples)
```

[37]:
```
KruskalResult(statistic=4887.593854046478, pvalue=0.0)
```

Donat que el p-value és < 0.05 (el valor de significació escollit), podem concloure que hi ha diferències de preu estadísticament significatives entre les ofertes de les diferents agències.

4.5 Model de regressió

Anem a construir un model de regressió lineal que ens permeti fer prediccions sobre el preu dels habitatges. Per fer això, primer haurem de fer unes transformacions a les dades perquè siguin manejables.

4.5.1 Codificació de les variables quantitatives

En un model de regressió no podem treballar directament amb dades categòriques. Hem de codificar-les per poder-les incloure en el nostre model. Optarem per One-Hot-Encoding, que ens permet introduir variables *dummy* per cada una de les categòries d'una variable.

[38]:
```
apartments.realestate.value_counts()
```

[38]:
```
ENGEL & VOELKERS                          836
Homelike                                  760
APROPERTIES REAL ESTATE Nº Aicat 6388     481
SH BARCELONA                              381
AREA CASA                                 332
                                         …
ESTUDI FELIP SEGON                          1
MARTINEZ GALLARDO, GLORIA                   1
GOLDMAX                                     1
AINCAT - SANT BOI DE LLOBREGAT              1
CG ASSESSORS                                1
Name: realestate, Length: 1046, dtype: int64
```

Veiem que per la variable realestate tenim moltes categories. Per reduir-ne el número, les classificarem segons el nombre d'habitatges que posen en lloguer. Anem a veure com es distribueix la quantitat d'habitatges que té cada immobiliària.

[39]:
```
counts_realestate = apartments.realestate.value_counts().to_frame().
↪reset_index()
counts_realestate.columns = ['realestate', 'counts']

counts_realestate.describe()
```

[39]:
```
            counts
count  1046.000000
mean      9.334608
std      42.954420
min       1.000000
25%       1.000000
50%       3.000000
75%       7.000000
max     836.000000
```

[40]:
```
counts_realestate.boxplot()
```

[40]: <AxesSubplot:>

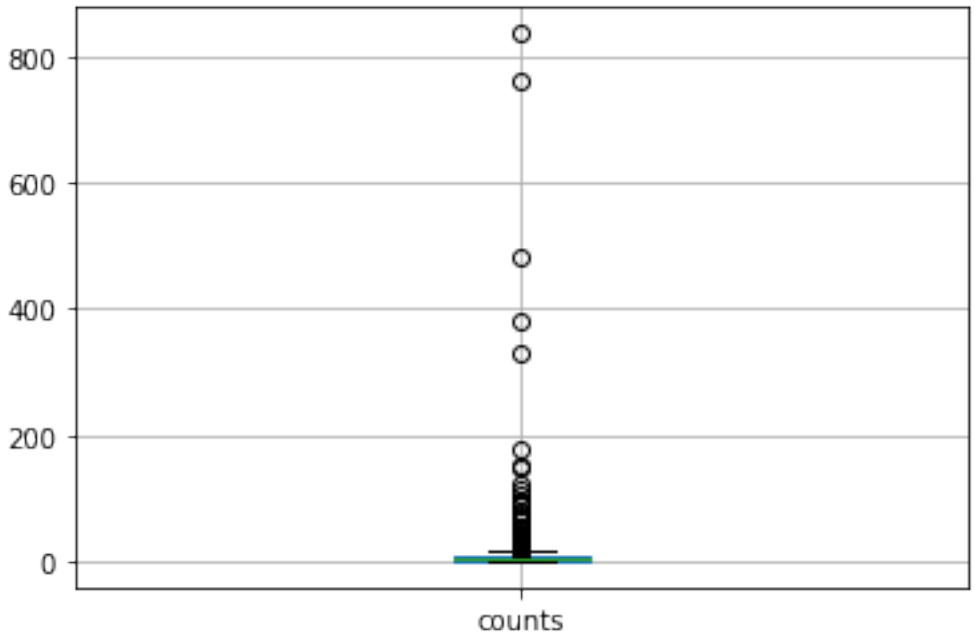

Explorant les dades hem vist que TECNOCASA apareix disgregada en diferents oficines. Comencem per assignar-li la mateixa immobiliària

[41]:
```
counts_realestate[counts_realestate.realestate.astype(str).str.
↪contains('TECNOCASA')]
```

[41]:

	realestate	counts
55	TECNOCASA RIERA ALTA MAR	24
122	TECNOCASA - ESTUDI AVINGUDA DE ROMA	13
190	TECNOCASA	9
386	TECNOCASA - ESTUDI MARINA 311	4
402	TECNOCASA-ESTUDI GRAN DE SANT ANDREU	4
466	TECNOCASA AVDA. MISTRAL	3
505	TECNOCASA - PISOS BORNE MAR	3
515	TECNOCASA - HOME GUINARDO	3
525	TECNOCASA - PROJECTE LA PROSPERITAT	3
582	TECNOCASA ESTUDI MERIDIANA	2
624	TECNOCASA - ESTUDI CAP MARAGALL	2
634	TECNOCASA - ESTUDI PROJECTE SANT ANDREU	2
691	TECNOCASA - ESTUDI NOU GAUDI	1
761	TECNOCASA - ESTUDI NAPOLS	1
904	TECNOCASA - ESTUDIO PROYECTO MARAGALL 2004	1

[42]:
```
apartments.loc[apartments.realestate.astype(str).str.
 ↪contains('TECNOCASA'),'realestate'] = 'TECNOCASA'
counts_realestate = apartments.realestate.value_counts().to_frame().
 ↪reset_index()
counts_realestate.columns = ['realestate', 'counts']
```

Farem la suposició on tots aquells valors de realstate que només tinguin un habitatge els etiquetarem com a propietaris particulars.

[43]:
```
particulars = counts_realestate[counts_realestate.counts==1].realestate
apartments.loc[apartments.realestate.isin(particulars),"realestate_size"] =␣
 ↪'Particular'
```

Entre 2 i 10, els classificarem com a petits propietaris.

[44]:
```
petits_propietaris = counts_realestate[np.logical_and(counts_realestate.
 ↪counts>1, counts_realestate.counts<=10)].realestate
apartments.loc[apartments.realestate.
 ↪isin(petits_propietaris),"realestate_size"] = 'Petit'
```

Entre 11 i 50 els classificarem com a propietaris mitjans.

[45]:
```
mitja = counts_realestate[np.logical_and(counts_realestate.counts>10,␣
 ↪counts_realestate.counts<=50)].realestate
apartments.loc[apartments.realestate.isin(mitja),"realestate_size"] = 'Mitja'
```

Més de 50 i menys de 300 com a grans propietaris

[46]:
```
grans = counts_realestate[np.logical_and(counts_realestate.counts>50,␣
 ↪counts_realestate.counts<=300)].realestate
apartments.loc[apartments.realestate.isin(grans),"realestate_size"] = 'Grans'
```

Més de 300, com a molt grans propietaris.

[47]:
```
molt_grans = counts_realestate[counts_realestate.counts>300].realestate
apartments.loc[apartments.realestate.isin(molt_grans),"realestate_size"] =␣
 ↪'Molt grans'
```

Hem simplificat notablement la informació sobre les immobiliàries.

[48]:
```
apartments.realestate_size.astype('category')
apartments.realestate_size.value_counts()
```

[48]:
```
Molt grans    2790
Mitja         2619
Petit         2276
Grans         1721
Particular     358
Name: realestate_size, dtype: int64
```

Ara codifiquem les variables:

[49]:
```
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import OneHotEncoder

apartments_regression = apartments.
 ↪drop(columns=['realestate','building_type','link','neighb_meanprice','diff_mitjana'])
cat_labels = apartments_regression.select_dtypes(include=['object',␣
 ↪'category','bool']).columns.to_list()
numeric_labels = apartments_regression.select_dtypes(include=['float64',␣
 ↪'int']).columns.to_list()

preprocessor = ColumnTransformer([('encoder', OneHotEncoder(), cat_labels)],
                    remainder='passthrough'
                )
apartments_regression_cod = preprocessor.fit_transform(apartments_regression)
cat_labels_encoded = preprocessor.named_transformers_['encoder'].
 ↪get_feature_names(cat_labels)
new_labels = np.concatenate([cat_labels_encoded,numeric_labels])

apartments_regression_cod = pd.DataFrame(apartments_regression_cod.todense(),␣
 ↪columns=new_labels)
apartments_regression_cod
```

[49]:

	building_subtype_Apartment	building_subtype_Attic	\
0	0.0	0.0	
1	0.0	0.0	
2	0.0	0.0	
3	0.0	0.0	
4	1.0	0.0	
…	…	…	
9759	1.0	0.0	
9760	1.0	0.0	
9761	0.0	0.0	
9762	1.0	0.0	
9763	0.0	0.0	

	building_subtype_CountryHouse	building_subtype_Duplex	\
0	0.0	0.0	
1	0.0	0.0	
2	0.0	0.0	
3	0.0	0.0	
4	0.0	0.0	
…	…	…	
9759	0.0	0.0	
9760	0.0	0.0	
9761	1.0	0.0	

```
9762                          0.0                       0.0
9763                          0.0                       0.0

      building_subtype_Flat  building_subtype_GroundFloorWithGarden  \
0                       0.0                                     0.0
1                       1.0                                     0.0
2                       0.0                                     0.0
3                       1.0                                     0.0
4                       0.0                                     0.0
…                       …                                       …
9759                    0.0                                     0.0
9760                    0.0                                     0.0
9761                    0.0                                     0.0
9762                    0.0                                     0.0
9763                    1.0                                     0.0

      building_subtype_House_Chalet  building_subtype_Loft  \
0                               0.0                    0.0
1                               0.0                    0.0
2                               0.0                    0.0
3                               0.0                    0.0
4                               0.0                    0.0
…                               …                      …
9759                            0.0                    0.0
9760                            0.0                    0.0
9761                            0.0                    0.0
9762                            0.0                    0.0
9763                            0.0                    0.0

      building_subtype_SemiDetached  building_subtype_SemidetachedHouse  …  \
0                               0.0                                 0.0  …
1                               0.0                                 0.0  …
2                               0.0                                 0.0  …
3                               0.0                                 0.0  …
4                               0.0                                 0.0  …
…                               …                                   …  …
9759                            0.0                                 0.0  …
9760                            0.0                                 0.0  …
9761                            0.0                                 0.0  …
9762                            0.0                                 0.0  …
9763                            0.0                                 0.0  …

      realestate_size_Molt grans  realestate_size_Particular  \
0                            0.0                         0.0
1                            0.0                         0.0
2                            0.0                         0.0
3                            0.0                         0.0
```

```
4                            0.0                          0.0
…                            …                            …
9759                         1.0                          0.0
9760                         1.0                          0.0
9761                         1.0                          0.0
9762                         1.0                          0.0
9763                         0.0                          0.0

      realestate_size_Petit  bathrooms  discount  latitude  longitude  \
0                       1.0        1.0       0.0  41.37723   2.160380
1                       1.0        1.0       0.0  41.43157   2.169108
2                       1.0        1.0       0.0  41.37141   2.144235
3                       1.0        2.0       0.0  41.36364   2.139371
4                       1.0        1.0       0.0  41.38046   2.160540
…                       …          …         …         …          …
9759                    0.0        1.0       0.0  41.37645   2.142625
9760                    0.0        2.0       0.0  41.38043   2.152265
9761                    0.0       21.0   30000.0  41.42890   2.167005
9762                    0.0        7.0       0.0  41.42745   2.167871
9763                    1.0        4.0       0.0  41.39231   2.145066

        price  rooms  sqft_m2
0       320.0    0.0     15.0
1       400.0    2.0     63.0
2       430.0    0.0     17.0
3       450.0    1.0     29.0
4       450.0    0.0     25.0
…       …    …       …
9759  22839.0    2.0     54.0
9760  23092.0    3.0     85.0
9761  25000.0   21.0   2500.0
9762  28279.0    8.0    550.0
9763  29000.0    4.0    600.0

[9764 rows x 99 columns]
```

[50]:
```
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import cross_val_score
from sklearn.preprocessing import StandardScaler

from statsmodels.api import OLS
import statsmodels.api as sm

X = apartments_regression_cod.drop(columns = 'price')
y = apartments_regression_cod['price']
reg = OLS(y,X).fit()
```

```
reg.summary()
```

[50]:
```
<class 'statsmodels.iolib.summary.Summary'>
"""
                            OLS Regression Results
==============================================================================
Dep. Variable:                  price   R-squared:                       0.595
Model:                            OLS   Adj. R-squared:                  0.591
Method:                 Least Squares   F-statistic:                     154.6
Date:                Mon, 04 Jan 2021   Prob (F-statistic):               0.00
Time:                        12:31:12   Log-Likelihood:                -79351.
No. Observations:                9764   AIC:                         1.589e+05
Df Residuals:                    9671   BIC:                         1.596e+05
Df Model:                          92
Covariance Type:            nonrobust
==============================================================================
                                                 coef    std err
t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
building_subtype_Apartment                    4211.8233   5729.218
0.735      0.462   -7018.643    1.54e+04
building_subtype_Attic                        4117.7463   5729.957
0.719      0.472   -7114.168    1.53e+04
building_subtype_CountryHouse                -1.604e+04   5912.692
-2.713      0.007   -2.76e+04   -4450.380
building_subtype_Duplex                       3822.2003   5731.142
0.667      0.505   -7412.038    1.51e+04
building_subtype_Flat                         3788.4442   5730.031
0.661      0.509   -7443.617     1.5e+04
building_subtype_GroundFloorWithGarden        3884.5898   5726.958
0.678      0.498   -7341.446    1.51e+04
building_subtype_House_Chalet                 4368.3338   5737.173
0.761      0.446   -6877.726    1.56e+04
building_subtype_Loft                         3989.0087   5728.314
0.696      0.486   -7239.687    1.52e+04
building_subtype_SemiDetached                 4825.7286   5742.887
0.840      0.401   -6431.531    1.61e+04
building_subtype_SemidetachedHouse            3256.8293   5737.739
0.568      0.570   -7990.340    1.45e+04
building_subtype_Study                        3812.6296   5730.310
0.665      0.506   -7419.977     1.5e+04
conservation_state_-1.0                       4066.8750   1.05e+04
0.387      0.699   -1.65e+04    2.47e+04
conservation_state_1.0                        4099.3003   1.05e+04
0.390      0.696   -1.65e+04    2.47e+04
```

```
conservation_state_2.0                                          4055.9893   1.05e+04
0.386      0.699   -1.65e+04    2.47e+04
conservation_state_3.0                                          4016.3879   1.05e+04
0.382      0.702   -1.66e+04    2.46e+04
conservation_state_4.0                                          3716.2390   1.05e+04
0.353      0.724   -1.69e+04    2.43e+04
conservation_state_8.0                                          4082.0489   1.05e+04
0.388      0.698   -1.65e+04    2.47e+04
floor_elevator_False                                            1.204e+04   3.15e+04
0.382      0.703   -4.97e+04    7.38e+04
floor_elevator_True                                              1.2e+04   3.15e+04
0.381      0.703   -4.98e+04    7.38e+04
is_new_construction_False                                       1.135e+04   3.15e+04
0.360      0.719   -5.04e+04    7.31e+04
is_new_construction_True                                        1.269e+04   3.15e+04
0.402      0.687   -4.91e+04    7.45e+04
neighbourhood_can baró                                           164.3599    986.007
0.167      0.868   -1768.420    2097.139
neighbourhood_can peguera                                        404.1565   1292.205
0.313      0.754   -2128.836    2937.149
neighbourhood_canyelles                                          133.2780   1175.588
0.113      0.910   -2171.121    2437.677
neighbourhood_ciutat meridiana                                   326.0711   1343.437
0.243      0.808   -2307.346    2959.488
neighbourhood_diagonal mar i el front marítim del poblenou      1387.0103    953.552
1.455      0.146    -482.151    3256.172
neighbourhood_el baix guinardó                                   318.8832    959.239
0.332      0.740   -1561.426    2199.193
neighbourhood_el barri gòtic                                     373.1920    892.265
0.418      0.676   -1375.834    2122.218
neighbourhood_el besòs i el maresme                              684.5552    978.451
0.700      0.484   -1233.413    2602.523
neighbourhood_el bon pastor                                      548.7602   1118.618
0.491      0.624   -1643.966    2741.486
neighbourhood_el camp d'en grassot i gràcia nova                 278.4870    946.572
0.294      0.769   -1576.993    2133.967
neighbourhood_el camp de l'arpa del clot                         363.9740    957.908
0.380      0.704   -1513.726    2241.674
neighbourhood_el carmel                                          149.7152    988.664
0.151      0.880   -1788.273    2087.704
neighbourhood_el clot                                            405.9271    959.511
0.423      0.672   -1474.915    2286.770
neighbourhood_el coll                                            137.1961    976.566
0.140      0.888   -1777.078    2051.470
neighbourhood_el congrés i els indians                           362.0409    993.041
0.365      0.715   -1584.528    2308.609
neighbourhood_el fort pienc                                      370.1739    927.200
```

```
0.399      0.690   -1447.332    2187.679
neighbourhood_el guinardó                                  282.7792    976.880
0.289      0.772   -1632.110    2197.668
neighbourhood_el parc i la llacuna del poblenou            449.0932    925.325
0.485      0.627   -1364.738    2262.925
neighbourhood_el poble sec - aei parc montjuïc             270.9089    872.471
0.311      0.756   -1439.317    1981.135
neighbourhood_el poblenou                                  612.5381    938.870
0.652      0.514   -1227.843    2452.919
neighbourhood_el putxet i el farró                         145.7862    947.153
0.154      0.878   -1710.831    2002.404
neighbourhood_el raval                                     230.3642    888.162
0.259      0.795   -1510.619    1971.348
neighbourhood_el turó de la peira                          351.7656   1012.835
0.347      0.728   -1633.603    2337.134
neighbourhood_horta                                        286.5606   1011.921
0.283      0.777   -1697.017    2270.138
neighbourhood_hostafrancs                                  827.3325    881.660
0.938      0.348    -900.907    2555.572
neighbourhood_l'antiga esquerra de l'eixample              367.6466    907.478
0.405      0.685   -1411.200    2146.493
neighbourhood_la barceloneta                               539.8316    888.808
0.607      0.544   -1202.418    2282.081
neighbourhood_la bordeta                                    55.4799    871.401
0.064      0.949   -1652.649    1763.609
neighbourhood_la dreta de l'eixample                       615.9862    916.977
0.672      0.502   -1181.480    2413.452
neighbourhood_la font d'en fargues                        2581.6406   1015.508
2.542      0.011     591.033    4572.248
neighbourhood_la font de la guatlla                        139.9752    875.859
0.160      0.873   -1576.893    1856.843
neighbourhood_la guineueta                                 341.2280   1064.731
0.320      0.749   -1745.867    2428.323
neighbourhood_la marina de port                           -131.3133    856.279
-0.153      0.878   -1809.799    1547.172
neighbourhood_la maternitat i sant ramon                   -57.8130    889.849
-0.065      0.948   -1802.103    1686.477
neighbourhood_la nova esquerra de l'eixample               264.6756    895.029
0.296      0.767   -1489.768    2019.119
neighbourhood_la prosperitat                               284.2654   1045.616
0.272      0.786   -1765.361    2333.892
neighbourhood_la sagrada família                           403.4895    943.072
0.428      0.669   -1445.129    2252.108
neighbourhood_la sagrera                                   421.6366    994.712
0.424      0.672   -1528.208    2371.481
neighbourhood_la salut                                     213.5273    960.671
0.222      0.824   -1669.590    2096.645
```

```
neighbourhood_la teixonera                                  -295.2657    993.267
-0.297      0.766   -2242.277    1651.745
neighbourhood_la trinitat nova                               218.3446   1114.169
0.196       0.845   -1965.661    2402.350
neighbourhood_la trinitat vella                              342.9484   1081.029
0.317       0.751   -1776.095    2461.992
neighbourhood_la vall d'hebron                               -65.8449   1154.439
-0.057      0.955   -2328.788    2197.098
neighbourhood_la verneda i la pau                            468.2804   1001.635
0.468       0.640   -1495.133    2431.694
neighbourhood_la vila de gràcia                              398.9947    936.240
0.426       0.670   -1436.232    2234.221
neighbourhood_les corts                                      198.8403    904.250
0.220       0.826   -1573.679    1971.360
neighbourhood_les roquetes                                   306.0658   1090.569
0.281       0.779   -1831.677    2443.809
neighbourhood_les tres torres                                223.3326    931.064
0.240       0.810   -1601.748    2048.413
neighbourhood_montbau                                        253.4808   1065.395
0.238       0.812   -1834.916    2341.877
neighbourhood_navas                                          429.9618    973.374
0.442       0.659   -1478.055    2337.979
neighbourhood_pedralbes                                      379.3253    916.557
0.414       0.679   -1417.318    2175.969
neighbourhood_porta                                          389.7852   1020.063
0.382       0.702   -1609.752    2389.322
neighbourhood_sant andreu                                    361.1188   1015.544
0.356       0.722   -1629.560    2351.798
neighbourhood_sant antoni                                    259.7658    893.451
0.291       0.771   -1491.585    2011.116
neighbourhood_sant genís dels agudells                       747.4315   1046.185
0.714       0.475   -1303.310    2798.173
neighbourhood_sant gervasi - galvany                         423.1587    926.455
0.457       0.648   -1392.888    2239.205
neighbourhood_sant gervasi - la bonanova                     418.7284    948.482
0.441       0.659   -1440.494    2277.951
neighbourhood_sant martí de provençals                       425.9120    979.172
0.435       0.664   -1493.470    2345.294
neighbourhood_sant pere, santa caterina i la ribera          424.8387    901.497
0.471       0.637   -1342.284    2191.962
neighbourhood_sants                                           37.0572    881.130
0.042       0.966   -1690.143    1764.257
neighbourhood_sarrià                                         377.6531    932.658
0.405       0.686   -1450.553    2205.859
neighbourhood_torre baró                                     310.9440   1334.257
0.233       0.816   -2304.478    2926.366
neighbourhood_vallcarca i els penitents                      224.6084    964.374
```

```
0.233      0.816   -1665.766    2114.982
neighbourhood_vallvidrera, el tibidabo i les planes          56.0155    987.799
0.057      0.955   -1880.277    1992.308
neighbourhood_verdun                                        507.7932   1128.550
0.450      0.653   -1704.401    2719.987
neighbourhood_vilapicina i la torre llobeta                 308.4005   1003.745
0.307      0.759   -1659.149    2275.950
realestate_size_Grans                                      4898.8523   1.26e+04
0.389      0.698   -1.98e+04    2.96e+04
realestate_size_Mitja                                      4729.0675   1.26e+04
0.375      0.708      -2e+04    2.94e+04
realestate_size_Molt grans                                 5029.4246   1.26e+04
0.399      0.690   -1.97e+04    2.97e+04
realestate_size_Particular                                 4674.8737   1.26e+04
0.371      0.711      -2e+04    2.94e+04
realestate_size_Petit                                      4704.6224   1.26e+04
0.373      0.709      -2e+04    2.94e+04
bathrooms                                                   295.9737     17.234
17.173      0.000     262.191     329.757
discount                                                      0.3119      0.040
7.813      0.000       0.234       0.390
latitude                                                   -575.7537   2244.014
-0.257      0.798   -4974.490    3822.983
longitude                                                 -5804.8852   2067.011
-2.808      0.005   -9856.660   -1753.110
rooms                                                       -44.2087     10.246
-4.315      0.000     -64.293     -24.125
sqft_m2                                                      11.0921      0.220
50.319      0.000      10.660      11.524
==============================================================================
Omnibus:                    14896.749   Durbin-Watson:                   0.944
Prob(Omnibus):                  0.000   Jarque-Bera (JB):         21815890.159
Skew:                           9.066   Prob(JB):                         0.00
Kurtosis:                     233.857   Cond. No.                     1.29e+16
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly
specified.
[2] The smallest eigenvalue is 8.34e-24. This might indicate that there are
strong multicollinearity problems or that the design matrix is singular.
"""
```

[51]:
```
import scipy.stats as stats
res = reg.resid # residuals
fig = sm.qqplot(res, stats.t, fit=True, line="45")
```

```
plt.title('Q-Q plot')
plt.show()
```

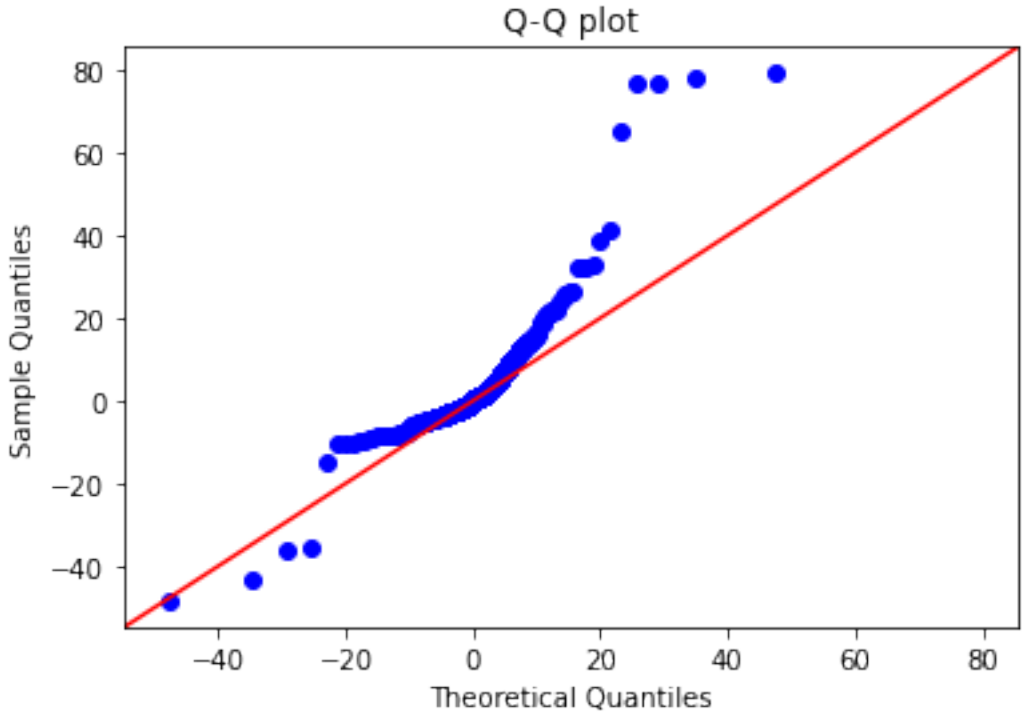

Veiem que el model de regressió lineal no ens dóna una capacitat predictiva gaire elevada, amb un R^2 proper al 0,6. Al resum del model, observem que moltes de les variables categòriques codificades no són especialment rellevants estadísticament. S'ha de mencionar, que el model de regressió lineal està enfocat a variables contínues que originin una resposta lineal, així que no es sorprenen aquests resultats. Al Q-Q plot veiem que no es compleixen les condicions d'homoscedasticitat, fet que podríem imaginar després de l'anàlisi de la variable price.

A continuació, provarem amb un model no lineal.

4.6 Regessió amb arbre

[52]:
```
from sklearn.model_selection import train_test_split
from sklearn.ensemble import GradientBoostingRegressor
import seaborn as sb;
from sklearn.ensemble import RandomForestClassifier



X = apartments_regression_cod.drop(columns = 'price')
y = apartments_regression_cod['price']
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.33,␣
↪random_state=42)
model = GradientBoostingRegressor( max_depth=3, min_samples_split=20)

model.fit(X_train, y_train)
```

[52]:
```
GradientBoostingRegressor(min_samples_split=20)
```

[53]:
```
accuracy = model.score(X_test, y_test)

print("El model té una precisió pel conjunt de test de:␣
↪"+str(round(accuracy*100,2))+"%")
```

```
El model té una precisió pel conjunt de test de: 66.59%
```

Sembla que aquest model millora la capacitat predictiva de la regressió lineal. La capacitat de treballar amb atributs categòrics i numèrics i la natura geomètrica de l'algoritme, són punts a favor d'aquest model que es traslladen en una millor predicció.

4.7 Classificació sobre preu inflat

Anem a construir un altre model, en aquest cas no per predir el preu, sinó per saber si aquest està inflat respecte a la mitjana del barri o no.

[54]:
```
apartments_classification = apartments.
↪drop(columns=['realestate','building_type','link','neighb_meanprice'])
cat_labels = apartments_classification.select_dtypes(include=['object',␣
↪'category','bool']).columns.to_list()
numeric_labels = apartments_classification.select_dtypes(include=['float64',␣
↪'int']).columns.to_list()

preprocessor = ColumnTransformer([('encoder', OneHotEncoder(), cat_labels)],
                    remainder='passthrough'
                )
apartments_classification = preprocessor.
↪fit_transform(apartments_classification)
cat_labels_encoded = preprocessor.named_transformers_['encoder'].
↪get_feature_names(cat_labels)
new_labels = np.concatenate([cat_labels_encoded,numeric_labels])

apartments_classification = pd.DataFrame(apartments_classification.todense(),␣
↪columns=new_labels)
apartments_classification['inflat'] = apartments_classification['diff_mitjana']␣
↪> 0
apartments_classification = apartments_classification.
↪drop(columns=['diff_mitjana'])
```

[55]:
```
from sklearn.metrics import accuracy_score

X = apartments_classification.drop(columns = 'inflat')
y = apartments_classification['inflat']

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.33,␣
 ↪random_state=42)

rf_tree = RandomForestClassifier(n_estimators=6, max_depth=10)

rf_tree.fit(X_train, y_train)

##CV

accuracy_cv_rf = cross_val_score(rf_tree, X_train, y_train)
print("El model té una precisió de validació creudada: "+str(round(np.
 ↪mean(accuracy_cv_rf)*100,2))+"%")

### Precisió conjunt de test

y_pred = rf_tree.predict(X = X_test)
accuracy_rd = accuracy_score(y_test, y_pred)
print("El model té una precisió pel conjunt de test de:␣
 ↪"+str(round(accuracy_rd*100,2))+"%")
```

```
El model té una precisió de validació creudada: 80.26%
El model té una precisió pel conjunt de test de: 81.69%
```

Obtenim bons resultats per aquest classificador, tant en el conjunt de test com el de validació creuada.

4.8 Detecció de zones tensionades

A continuació, aprofitem que tenim les dades geogràfiques per veure si en podem treure alguna conclusió.

[56]:
```
plt.scatter(apartments.longitude,apartments.latitude, s=0.1, alpha=0.4,␣
 ↪cmap='viridis')
```

[56]:
```
<matplotlib.collections.PathCollection at 0x7f862c1efd30>
```

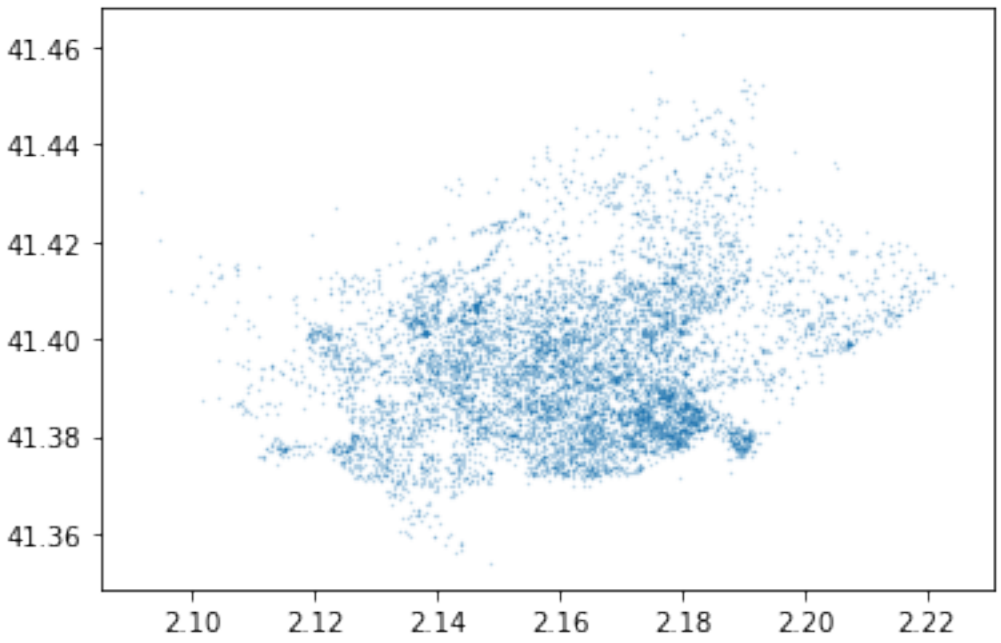

Realitzarem un agrupament segons la diferència sobre la mitjana i la posició i visualitzarem el resultat amb les coordenades espacials, per veure si observem algun patró.

Utilitzarem DBSCAN ja que ens permet detecció d'outliers i és sensible a estructures per densitat. L'objectiu de l'agrupament és trobar punts calents a la ciutat on el preu estigui inflat. Per això, treballarem només amb les dades que tinguin el preu per sobre la mitjana, agruparem segons la posició, i balancejarem els punts segons la diferència sobre la mitjana.

Per començar, fem un estudi de quin és el nombre òptim de clústers:

[57]:
```
from sklearn import cluster
from sklearn.preprocessing import scale

apartments_cl = apartments[apartments['diff_mitjana'] > 0].copy()
apartments_cl['diff_mitjana_positive'] = (apartments_cl['price']/
 ↪(apartments_cl['neighb_meanprice']*apartments_cl['sqft_m2']))-1
points = apartments_cl[["longitude", "latitude"]].values
X = apartments_cl[['longitude','latitude']].values

Nc = range(1, 22)
kmeans = [cluster.KMeans(n_clusters=i) for i in Nc]
kmeans
score = [kmeans[i].fit(X,sample_weight=apartments_cl.diff_mitjana_positive).
 ↪inertia_ for i in range(len(kmeans))]
score
plt.plot(Nc,score)
plt.xlabel('K')
```

```
plt.ylabel('SSE')
plt.title('Corba Elbow')
plt.xticks(Nc)
plt.show()
```

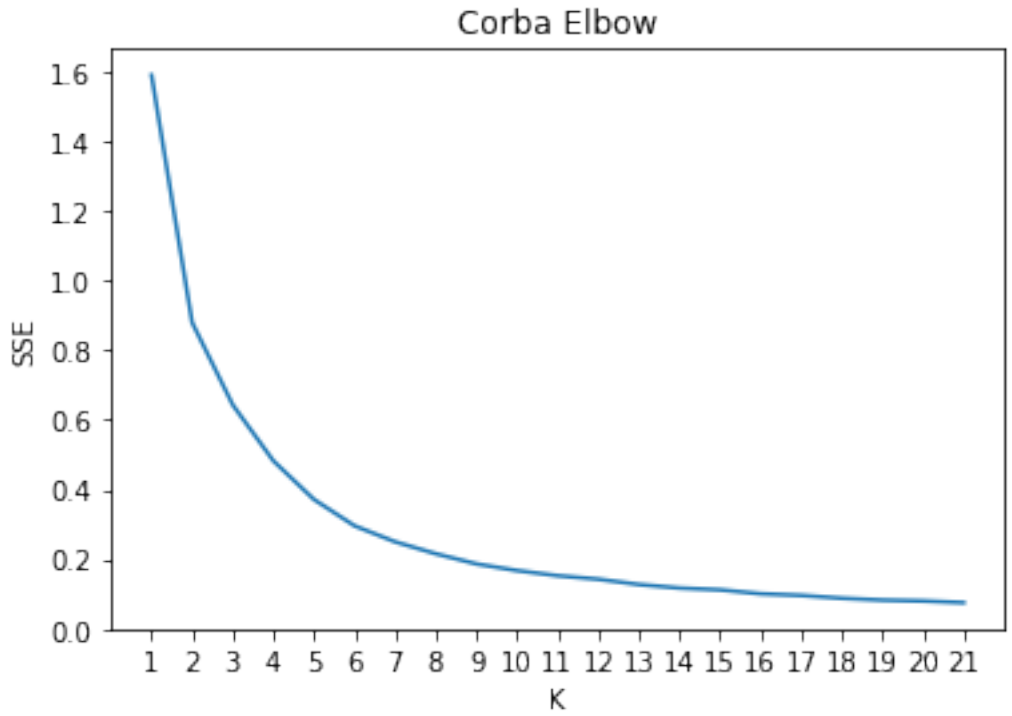

[58]:
```
from sklearn import cluster
from sklearn.preprocessing import scale
clustering = cluster.DBSCAN(eps=0.0015, min_samples=18).
 ↪fit(X,sample_weight=apartments_cl['diff_mitjana_positive'])

y_kmeans = clustering.
 ↪fit_predict(X,sample_weight=apartments_cl['diff_mitjana_positive'])
plt.figure(figsize=(10, 8))

apartments_cl['clusters'] = y_kmeans

plt.scatter(points[:, 0], points[:, 1], c=y_kmeans,alpha=1, s=0.3, cmap='prism')
plt.title("Agrupament per posició i diferència respecte a la mitjana")
```

[58]:
```
Text(0.5, 1.0, 'Agrupament per posició i diferència respecte a la mitjana')
```

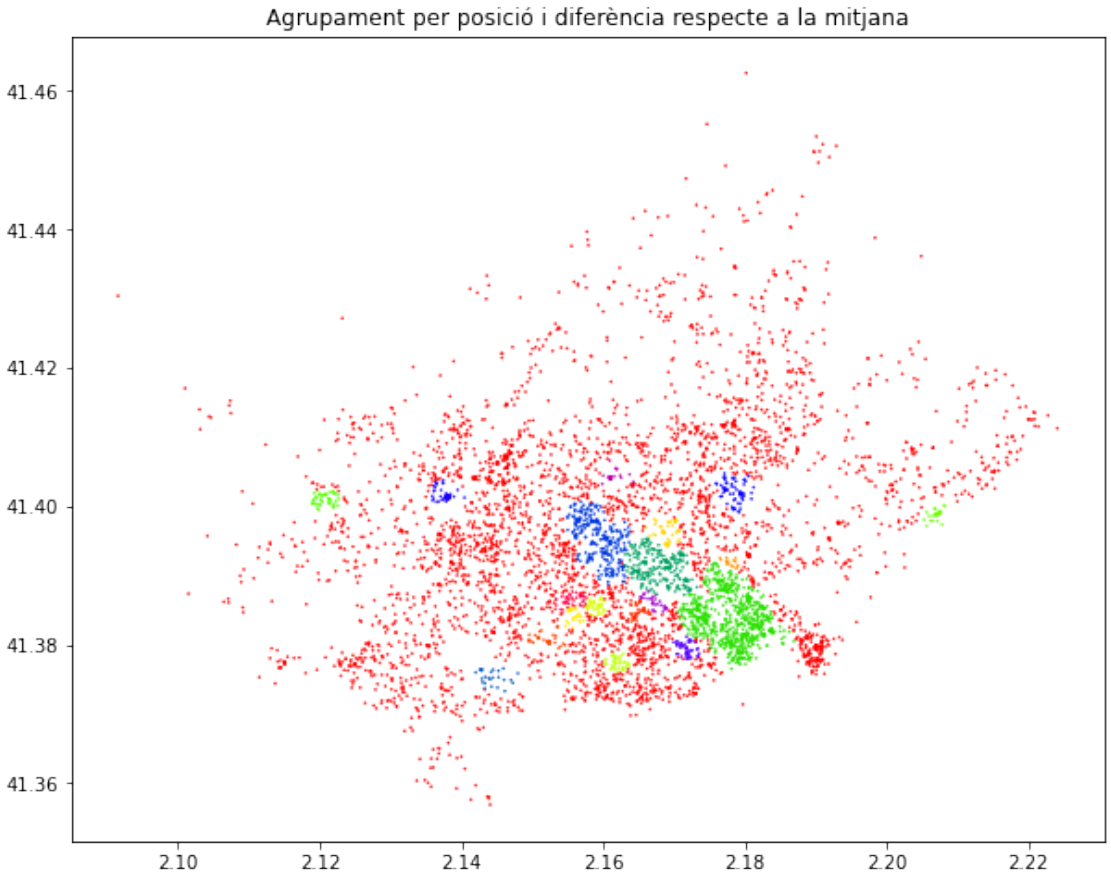

[59]:
```
fig = plt.figure(figsize=(10, 8))

ax1 = fig.add_subplot(111)
apartments_nclustered = apartments_cl[apartments_cl['clusters'] == -1]
ax1.scatter(apartments_nclustered.longitude, apartments_nclustered.latitude,␣
↪c=apartments_nclustered.clusters,alpha=0.1, s=0.3)

apartments_clustered = apartments_cl[apartments_cl['clusters'] != -1]
ax1.scatter(apartments_clustered.longitude, apartments_clustered.latitude,␣
↪c=apartments_clustered.clusters,alpha=1, s=0.6, cmap='tab20')
```

[59]:
```
<matplotlib.collections.PathCollection at 0x7f8678a79670>
```

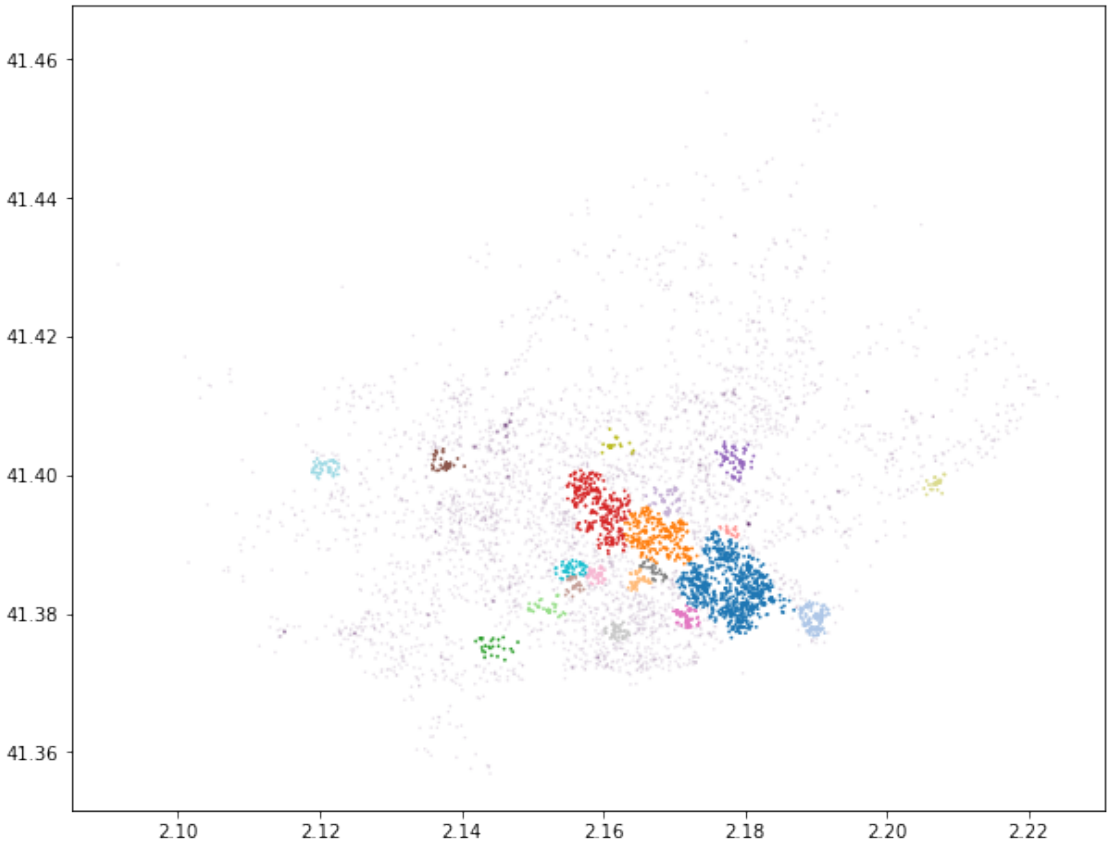

L'algorisme DBSCAN ens permet detectar outliers, que en aquest cas són elements que no s'han pogut relacionar amb cap clúster. Al segon gràfic els veiem en un color claret, mentre que els clústers en un color més fort i definit. Sembla que l'agrupament resultant respon a zones turístiques de la ciutat, que acostumen a ser zones tensionades.

5 Conclusions

Després de portar a terme l'anàlisi de les dades, podem presentar amb confiança les respostes als diferents objectius plantejats:

- Podem confirmar que existeixen diferències estadísticament significants entre els preus de lloguer dels diferents barris de la ciutat de Barcelona. Sembla un fet lògic, ja que a la majoria de ciutats existeixen barris on el preu és elevat, mentre que d'altres tenen preus més moderats (zones menys turístiques) o fins i tot preus sorprenentment baixos (zones conflictives).

[60]:
```
neighbourhood_mean_prices = apartments[['neighbourhood', 'price']].
 ↪groupby('neighbourhood')['price'].mean().sort_values()
fig = plt.figure(figsize=(16,12))
plt.xlabel('Preu mitjà')
neighbourhood_mean_prices.plot.barh(title='Preus mitjans per barri')
```

[60]: <AxesSubplot:title={'center':'Preus mitjans per barri'}, xlabel='Preu mitjà', ylabel='neighbourhood'>

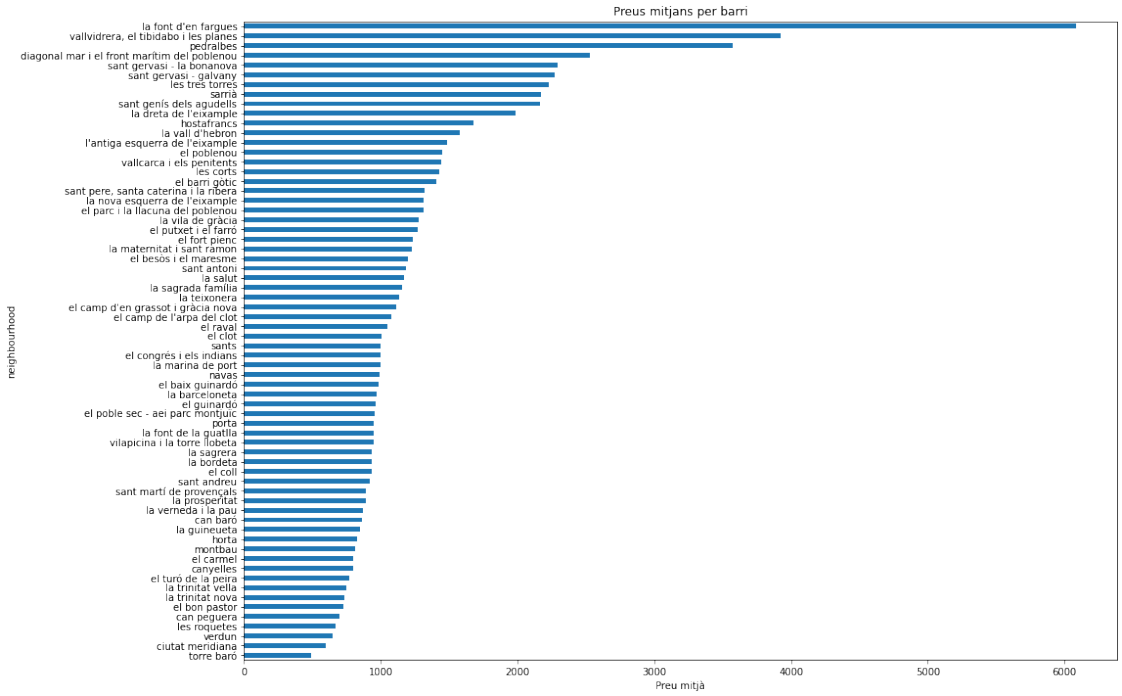

- Podem confirmar també que existeixen diferències estadísticament significants entre els preus de lloguer que ofereixen les diferents agències a la ciutat de Barcelona. Podem explicar aquestes diferències pel fet que sovint grans immobiliàries tenen una gran quota de mercat, especialment de pisos amb preus elevats, respecte a d'altres més petites i els particulars, per tant estan en una posició en la qual poden jugar amb els preus més lliurement. En part podem observar aquest fet visualment si mirem els preus mitjans segons la mida d'agència:

[61]:
```
realestate_size_mean_price = apartments[['realestate_size', 'price']].
 ↪groupby('realestate_size')['price'].mean().sort_values()
fig = plt.figure(figsize=(16, 8))
plt.xlabel('Preu mitjà')
realestate_size_mean_price.plot.barh(title="Preus mitjans per tamany d'agència")
```

[61]: <AxesSubplot:title={'center':"Preus mitjans per tamany d'agència"}, xlabel='Preu mitjà', ylabel='realestate_size'>

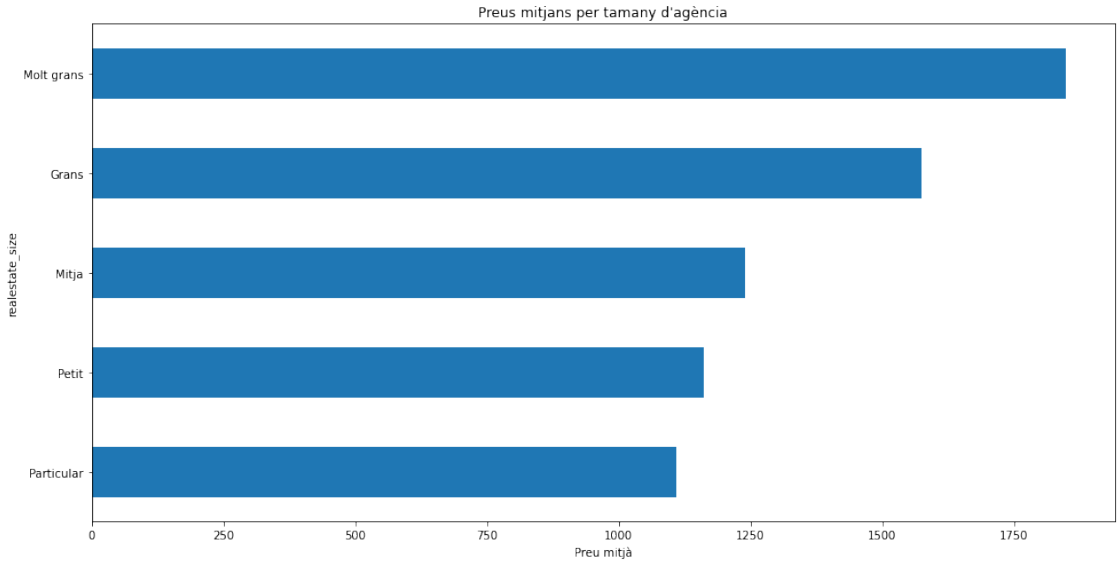

- Es poden construir **models de regressió** per intentar predir el preu de lloguer d'un habitatge. Tot i això, els models resultants que hem construït a aquesta pràctica (regressió lineal i regressió amb arbre) tenen una **precisió per sota del 70%** en ambdós casos. Com a alternativa, podríem estudiar l'efecte dels valors extrems i proporcionar un model més precís per un rang de preus més acotat.
- El model de classificació supervisat que hem entrenat ens permet saber amb una precisió notable (~80%) si el preu d'un allotjament està inflat o no. Això pot ser útil per a avaluar, donades les característiques específiques d'un pis, si el preu és massa elevat. A priori, però, es tracta d'un model que s'hauria d'anar actualitzant sovint, ja que les mitjanes de preus dels organismes oficials canvien al llarg del temps, i són la base per la qual hem decidit si un preu està o no inflat.
- El model de classificació no supervisat que hem creat mitjançant l'algorisme DBSCAN (a priori no coneixem el nombre de clústers que podríem formar), ens ha permès confirmar que hi ha zones específiques de la ciutat on el preu està molt per sobre del preu mitjà que aporten els organismes oficials. Com s'ha comentat, sembla que correspon amb zones turístiques, per tant no sorprenen aquests resultats. Tot i això, existeix la **possibilitat que els organismes oficials emprin un altre criteri per determinar els preus mitjans dels barris**, ja que a la majoria d'ells el preu mitjà de les observacions està per sobre del preu mitjà proporcionat pels organismes oficials:

[62]:
```
overpriced_neighbourhoods = apartments.groupby('neighbourhood',␣
↪observed=True)['diff_mitjana'].mean().sort_values()
fig = plt.figure(figsize=(16, 12))
plt.xlabel('Diferència de preu (%)')
overpriced_neighbourhoods.plot.barh(title='Diferència de preu per barri␣
↪respecte mitjana oficial')
```

[62]: <AxesSubplot:title={'center':'Diferència de preu per barri respecte mitjana oficial'}, xlabel='Diferència de preu (%)', ylabel='neighbourhood'>

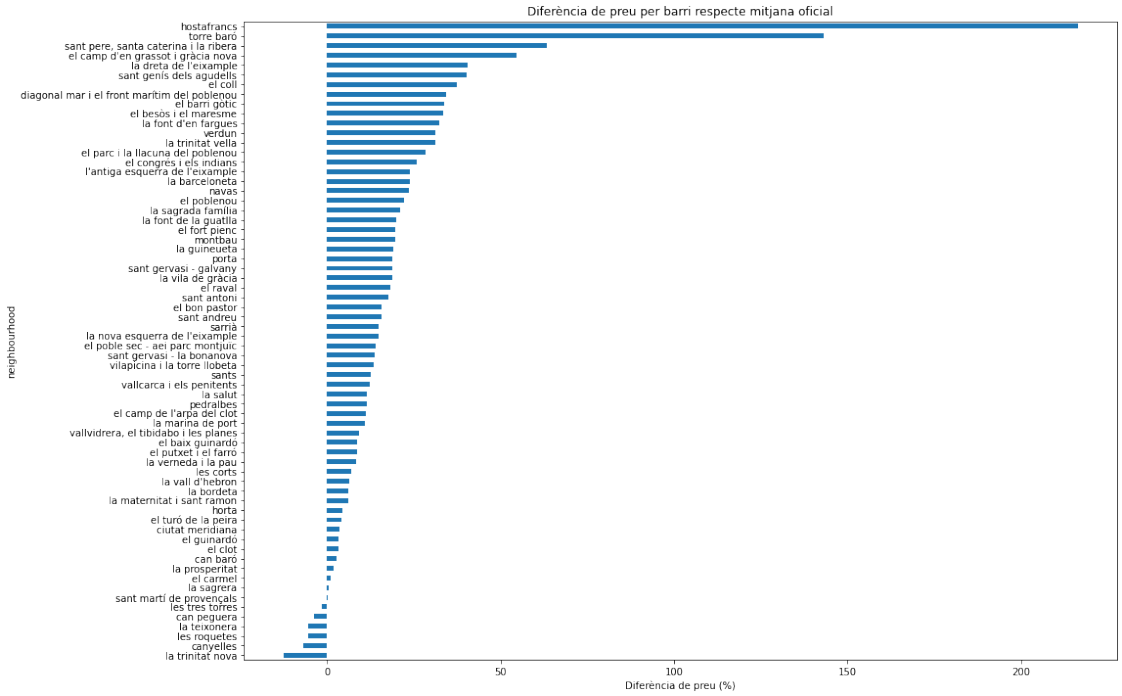

6 Taula de contribucions

Contribucions	Firma
Investigació prèvia	JMOB, PBL
Redacció de les respostes	JMOB, PBL
Desenvolupament codi	JMOB, PBL